

[L0-L1 核心本质与设计逻辑]

L0 一句话本质：通过列式物理存储与压缩块设计，将批量数据映射为 8192 行粒度的稀疏索引标记，利用 CPU SIMD 寄存器级向量化操作在大批量 Column 块上并行过滤与聚合，依靠异步 MergeTree 引擎及 ZooKeeper 协同保障大规模数据分片副本最终一致性的极速列存 OLAP 引擎。

L1 四句话逻辑：

- 分布式查询与网络协议** (M1) 支持原生 TCP 与 HTTP，通过两阶段分布式查询在各分片 (Shard) 上并发下推算子并由 Coordination 节点汇总。
- 向量化执行与 SIMD** (M2) 放弃单行 Volcano 模型，改用 Column 块作为迭代单元，用 CPU 硬件级的 SIMD 向量化指令提升单核数据计算吞吐。
- MergeTree 存储引擎** (M3) 采用 LSM-Tree 变体，将追加写入的数据段按分区 (Partition) 物理落盘，并在后台异步进行 Merge 归并排序合并。
- 稀疏索引与压缩块** (M4-M6) 配合 primary.idx 和 mark 标记文件以 8192 行为 Mark 粒度检索，通过 Block 级列式压缩及多种编码技术极大压榨 I/O。

[L2 存储引擎数据流演进拓扑]

• [SQL 查询请求] → [分布式解析下推] → [MinMax 分区过滤] → [Primary Key 稀疏 Mark 定位] → [Compressed Block 读取解压] → [SIMD 向量化 Filter/Aggregate] → [Shard 数据汇总] → [最终结果输出]

[M1.1] TCP/HTTP 原生协议与报文交互 (Network Protocol)

- 双重协议网关：**ClickHouse 同时支持高效率的原生 TCP 协议（默认 9000 端口）和兼容性极佳的 HTTP 协议（默认 8123 端口）。
- 块级报文序列化：**原生 TCP 采用自研二进制协议，数据报文按 Block（列式块）进行紧凑序列化传输，最大程度压榨网卡带宽。

[M1.2] 两阶段分布式查询执行下推 (Distributed Query Executor)

- 分布式 AST 分发：**分布式表（Distributed Engine）接收查询后，解析为分布式执行计划。
- 本地并行汇总：**第一阶段将 Query 重写，下推（Pushdown）至各 Shard 节点并行执行本地计算；第二阶段由 Coordinator 节点拉取各 Shard 的中间聚合结果（如 Hash 槽段）进行全局归并。

[M1.3] Shard / Replica 拓扑路由选择 (Topology Routing)

- 逻辑分片与物理副本：**Cluster 在配置中定义分片（Shard）和副本（Replica）。
- 动态路由探测：**写入分布式表时，根据 sharding_key 哈希值进行路由分配。查询时，Coordinator 自动探测副本延迟，优先路由至延迟最低的 Active Replica 节点。

[M1.4] ClickHouse FDW 外部表引擎挂载 (Foreign Data Wrapper)

- 异构联邦挂载：**支持 MySQL、PostgreSQL、ODBC、HDFS 等外部引擎。
- 算子物理下推：**在执行联邦查询时，CH 优化器解析 Where 过滤条件和 Limit 限制，将其转化为 SQL 下推到远端数据库执行，避免全表拉取。

[M2.1] ColumnVector 内存物理连续对齐 (Column Vector Layout)

- 内存数组连续性：**列式数据在内存中表示为 ColumnVector 结构。内部使用一片连续的 C++ 原始内存空间存储同一列的数据。
- 无指针跳转开销：**消除行式结构中对象指针的随机内存跳转，完美对齐 CPU L1/L2 缓存行，实现微秒级的内存寻址。

[M2.2] Vectorized Loop 块迭代机制 (Vectorized Iteration)

- 废弃虚函数循环：**完全废弃行式 Volcano 算子中每行数据都进行虚函数调用的高能耗设计。
- 大块流式直通：**算子间流转的单元为 Chunk（默认 65536 行 Column 数组）。在算子内部使用极简的紧凑 for 循环处理整个数组，大幅降低 CPU 分支预测失败率。

[M2.3] CPU SIMD 指令集硬件加速 (SIMD Optimizations)

- 并行向量流水线：**CH 代码深度集成了 SSE4.2、AVX2、AVX512 指令集。
- 硬件级并行过滤：**在执行如 WHERE col > 10 时，编译器将循环展开，利用 SIMD 寄存器单条指令同时对比 8/16 个数值，吞吐量直达硬件物理极限。

[M2.4] Projection 投影与 Materialized View 同步刷写 (Projections & MV)

- 投影列物理冗余：**Projection 允许在主表内对部分列按不同排序键物理冗余存储。
- 物化视图流式触发：**Materialized View 本质上是写触发器。当数据 Part 写入主表时，自动流式触发计算并写入关联的物化视图表，保障原子可见。

[M2.5] Memory Tracker 线程级内存追踪 (Memory Tracker)

- 层级内存计数器：**ClickHouse 在共享内存中为每个查询线程分配 MemoryTracker。
- 精确 OOM 拦截：**实时追踪查询分配的字节数。一旦超过 max_memory_usage 阈值，立即抛出内存超限异常终止查询，保护宿主机不被 OS OOM-Killer 杀死。

[M3.1] MergeTree Part 物理目录与文件结构 (Part Directory Layout)

- 分区物理硬隔离：**每个写入批次生成一个以 PartitionID_MinBlock_MaxBlock_Level 命名的物理 Part 目录。
- 列物理文件打散：**目录内每一列分别拥有 [column].bin（压缩数据）和 [column].mrk2（Mark 标记指针）文件，以及全局 primary.idx 稀疏索引。

[M3.2] 异步后台 Merge 归并合并流程 (Merge Task Pipeline)

- 碎片 Part 后台归并：**后台 Merge 线程池定期扫描表目录，将属于同一分区的多个小 Part 挑选出来。
- 归并排序物理去重：**执行流式归并排序（External Merge Sort），将老 Parts 合并为包含更大 Block 区间的新 Part，并将老 Parts 物理删除。

[M3.3] Row/Column TTL 声明周期物理擦除 (TTL Cleaning)

- 到期物理回收：**支持表级、列级及行级 TTL 定义。
- 合并时无感清除：**过期标记记录在 Part 的 ttl.txt 中。后台 Merge 进程合并数据块时，物理擦除过期行，或将过期列数据清空重置，实现零开销物理回收。

[M3.4] Mutation 异步非原子修改机制 (Mutations)

- 非事务性重写：**UPDATE/DELETE 被视为 Mutation 操作（通过 ALTER 语句触发）。
- 克隆 Part 重写：**ClickHouse 不支持行级事务锁，它通过复制原 Part 目录，在后台流式读取、过滤/修改并重新写入新 bin 文件的形式实现修改，代价极高。

[壹] ClickHouse 列式存储与执行折衷与异常防范矩阵 (ClickHouse Storage & Execution Trade-offs)

⚠️ **主键索引应该像 MySQL 一样越精准越好，且主键建得越多越方便多条件检索：** ClickHouse 采用稀疏索引（Sparse Index）。如果主键字段过多或基数过高，会导致内存中 primary.idx 物理膨胀，且稀疏索引无法精确定位单行，反而造成无用的全 Granule I/O 扫描。→ 仅对经常作为 Where 过滤条件且物理有序的低/中基数字段建主键。多条件检索使用二级“跳数索引”（Skip Index）或物化视图（Materialized View）进行物理重组加速。

⚠️ **像传统数据库那样，采用高并发高频次单行 INSERT 来实时更新数据：** MergeTree 每次写入都会生成一个独立的物理 Part。如果高频写入，后台 Merge 进程来不及归并合并，会导致 Part 数量暴增，触发 Too many parts in all data parts 写入限流甚至崩溃。→ 必须在客户端或使用 Buffer 表进行批量聚合写入。建议单次写入批次不少于 20000 行，或维持写入频率在每秒不超过 1 次，以给后台 Merge 归并留出充分的物理调度窗口。

⚠️ **通过频繁的 UPDATE 和 DELETE 语句来实时修改和删除数据状态：** MergeTree 的 UPDATE/DELETE 本质上是通过 Mutation 机制异步重写整个 Part 数据块。这会引发极高的磁盘 I/O 穿透和 CPU 重新编码开销，导致查询性能短时间内雪崩。→ 采用 ReplacingMergeTree 或 CollapsingMergeTree 引擎，通过写入标记行（Sign）或版本号，在后台 Merge 时自动物理去重，或者通过逻辑 Filter 规避物理重写。

T2 经典性能监控与诊断 SQL 指令字典